

EA991 - Laboratório de Aprendizado de Máquina

Aprendizado por
Transferência

Prof. Denis G. Fantinato
Prof. Levy Boccato





Transfer Learning

Suponha que você tenha 50 imagens de carros e 50 de bicicletas e queira construir um modelo para classificá-las. Como treinar um modelo usando esse conjunto de dados tão pequeno?

É possível treinar seu modelo do zero (*from scratch*), mas ele provavelmente apresentará sobreajuste. Nesse caso, pode-se utilizar o **conhecimento a partir de outras bases de dados**.


- Treinar modelos com alta precisão requer muitos dados. Por exemplo, o conjunto de dados ImageNet contém mais de 1 milhão de imagens. Em aplicações mais específicas, é difícil existir um conjunto de dados tão grande.
- Mesmo tendo um conjunto de dados massivo, os recursos computacionais necessários para treinar um modelo em toda a base podem ser bastante elevados.
- Mesmo com recursos computacionais à disposição, o treinamento pode levar dias (ou semanas).

Transfer Learning

Aprendizado por transferência: transferência de conhecimento entre diferentes tarefas.

Traditional ML


- Isolated, single task learning:
 - Knowledge is not retained or accumulated. Learning is performed w.o. considering past learned knowledge in other tasks



vs

Transfer Learning

- Learning of a new tasks relies on the previous learned tasks:
 - Learning process can be faster, more accurate and/or need less training data





Transfer Learning

- **Objetivo:**

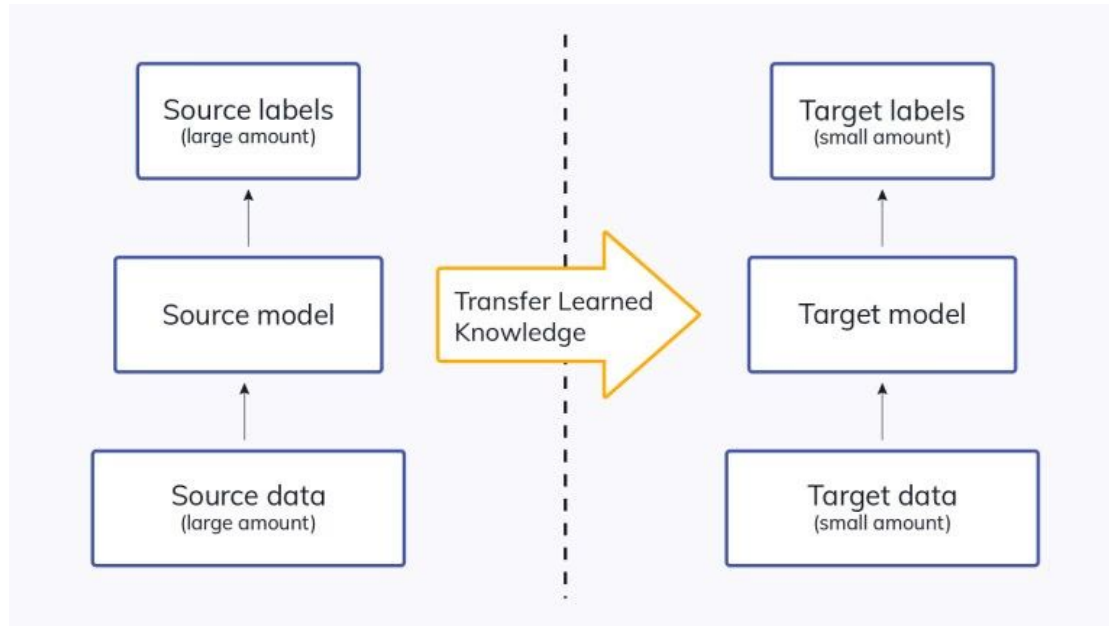
Aproveitar representações de atributos de um **modelo pré-treinado**, para que não seja necessário treinar um novo modelo do zero.

- **Ideia geral:**

- Os modelos pré-treinados geralmente são ajustados em conjuntos de dados massivos que são uma referência padrão no contexto do problema (por exemplo, em visão computacional).
- Os pesos obtidos dos modelos podem ser reutilizados em outras tarefas.

Transfer Learning

O aprendizado por transferência é particularmente útil quando se tem um pequeno conjunto de dados de treinamento.





Transfer Learning

A vantagem dos modelos pré-treinados é que eles são genéricos o suficiente para uso em outras aplicações do mundo real.

Todavia, é necessário que haja certo grau de similaridade entre os conjuntos de dados fonte e alvo para que o conhecimento possa ser reaproveitado/reutilizado.

Exemplo:

- Modelos treinados no conjunto de dados ImageNet podem ser usados em problemas de classificação de imagens do mundo real. Isso ocorre porque o conjunto de dados contém mais de 1.000 classes. É bastante provável que exista algum grau de similaridade entre os dados do conjunto ImageNet e a tarefa alvo.



Transfer Learning


- **Perspectivas de treinamento:**
 - Esses modelos podem ser usados diretamente para:
 - fazer previsões em novas tarefas, ou
 - integrados ao processo de treinamento de um novo modelo.
 - Incluir os modelos pré-treinados em um novo modelo resulta em menor tempo de treinamento e menor erro de generalização.

Treinamento por Transfer Learning

Um modelo é pré-treinado em um conjunto de dados fonte.

Em seguida, duas abordagens mais usuais são possíveis:

- ***Fine-tuning***: o modelo tem seus pesos refinados para a tarefa alvo (também chamada de tarefa *downstream*).




Treinamento por Transfer Learning

Um modelo é pré-treinado em um conjunto de dados fonte.

Em seguida, duas abordagens mais usuais são possíveis:

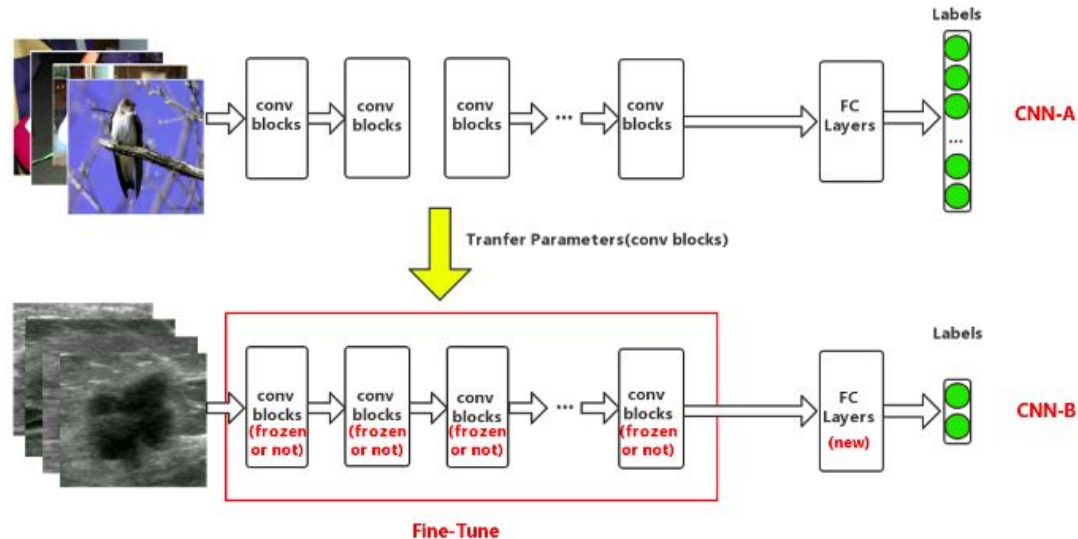
- ***Fine-tuning***: o modelo tem seus pesos refinados para a tarefa alvo (também chamada de tarefa *downstream*).
- ***Fixed feature extractor (freeze layers)***: Ajuste da topologia do modelo para a tarefa alvo, mantendo-se parte da estrutura com os pesos fixos.



Treinamento por Transfer Learning

No caso de *fine-tuning*, deve-se seguir os passos:

- 1) carregar o modelo pré-treinado (inicialização dos pesos do modelo) - pode ser necessário ajustar a(s) camada(s) final(is)
- 2) Fazer o treinamento (*fine-tuning*) utilizando o conjunto de dados da tarefa alvo.

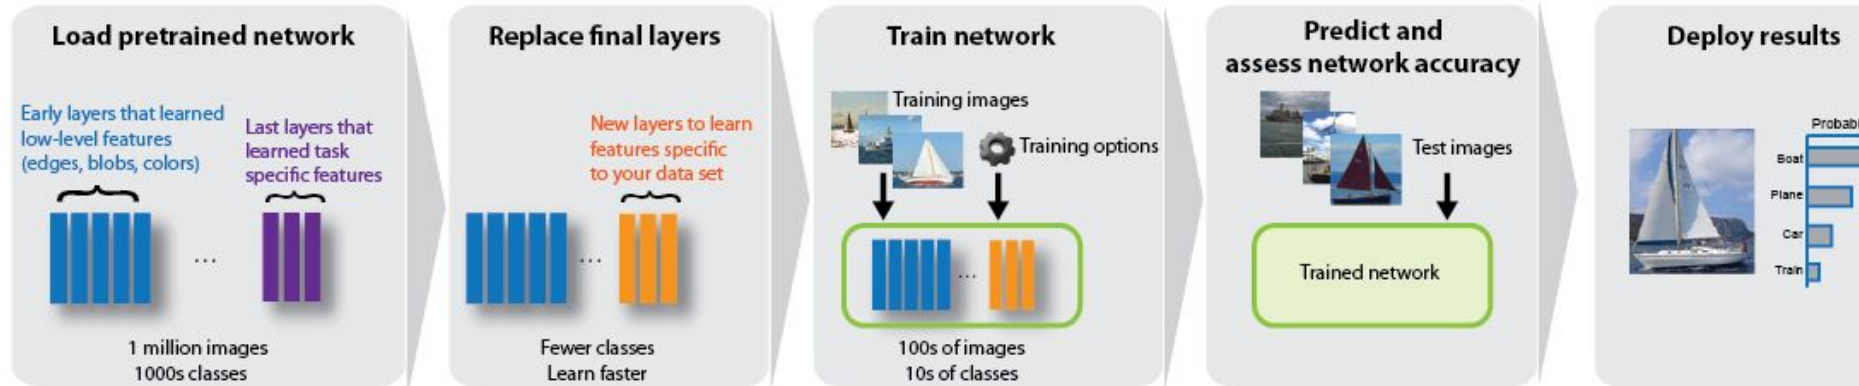


Treinamento por Transfer Learning

No caso de *fixed feature extractor (freeze-layers)*, deve-se seguir os passos:



Reuse Pretrained Network



Treinamento por Transfer Learning

